

UNIVERSITÉ DE GENÈVE

ANALYSE ET TRAITEMENT DE L'INFORMATION  
14X026

---

# TP5: Communications and probabilities

---

*Author:* Julien Python [120 Crédits]

*E-mail:* [julien.python@etu.unige.ch](mailto:julien.python@etu.unige.ch)

November 23, 2020



**UNIVERSITÉ  
DE GENÈVE**

---

**FACULTÉ DES SCIENCES**  
Département d'informatique

## Exercice 1


$$1) \quad p(X, Y, Z) = p(X) \cdot p(Y|X) \cdot p(Z|X, Y)$$

$$2) \quad p(X_1, X_2, X_3, X_4, X_5, X_6, X_7) = \\ p(X_1) p(X_2) p(X_3|X_1, X_2) p(X_4) p(X_5) \cdot p(X_6|X_3, X_4, X_5) \cdot \\ \cdot p(X_7|X_6)$$

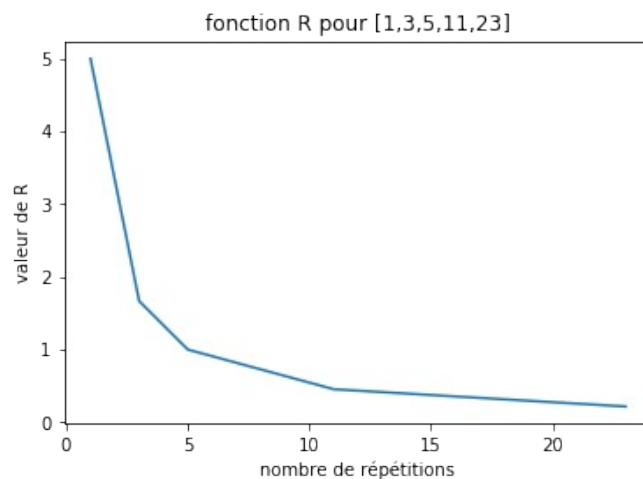
## Exercice 2

- i) J'ai effectué le résultat pour 1000 expériences afin d'être plus précis, et on obtient que l'espérance du nombre de caractères corrects des ces 1000 expériences vaut 590.676, donc ~40% d'erreur.
- ii) J'ai répété la même expérience pour  $n=3$ , où  $n$  est le nombre de répétitions, on obtient une espérance de 867 caractères corrects, ce qui représente un taux de ~13.3% d'erreur.
- iii) J'ai répété la même expérience pour  $n=5$ , où  $n$  est le nombre de répétitions, on obtient une espérance de 957.938 caractères correct, ce qui représente un taux de ~4.2% d'erreur
- Pour  $n=11$ , on obtient une espérance de 998.549 caractères correct, ce qui représente un taux de ~0.145% d'erreur.
- Pour  $n=23$ , on obtient une espérance de 1000 caractères correct, ce qui représente un taux de 0% d'erreur.

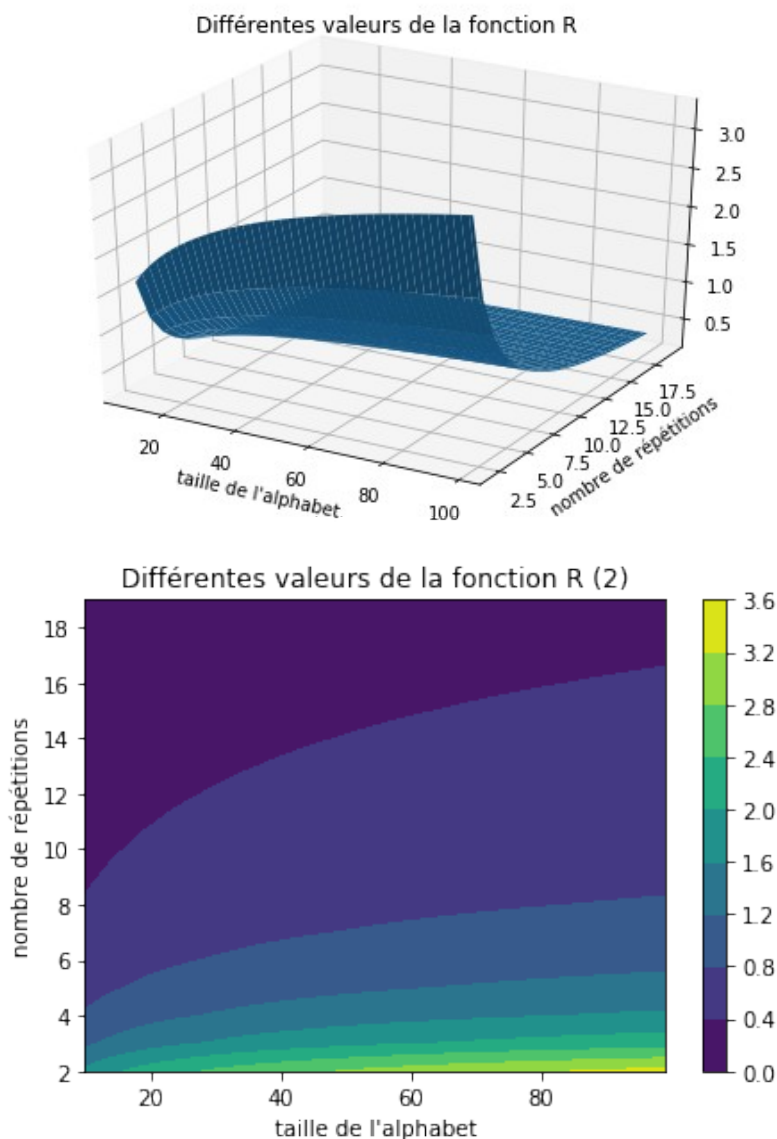
Comme on le remarque sur le graphe ci-dessous, peu après 10 l'erreur est très proche de 0.



iv) Si on regarde seulement la valeur de  $R$  par rapport aux nombre de répétitions proposée dans le début de l'exercice, on obtient un graphe suivant. On remarque que plus le nombre de répétitions avance, plus la valeur de  $R$  converge vers zéro.



Mais afin d'y voir plus clair, j'ai décidé d'y afficher dans un plot en 3 dimensions qui a comme axe R, n et M. En procédant ainsi, on obtient les graphes suivants :




Sur le premier graphe, on voit bien la forme des données et l'influence du nombre de répétitions qui fait tendre R vers zéro, mais aussi en augmentant l'alphabet pour peu de répétition la valeur de R augmente (même si elle n'appartient pas à l'intervalle  $[0,1]$ ). Sur le second graphe, on distingue clairement le comportement logarithmique de la valeur de R pour la relation entre la taille de l'alphabet et le nombre de répétitions. Ainsi, selon le taux de communication souhaité, on peut utiliser ce graphe pour choisir le nombre de répétition à effectuer pour un alphabet donné (ou inversement).

### Exercice 3


Dans cet exercice, nous allons travailler avec deux données, la première notée  $X$  est un vecteur qui est extrait d'une image de la jonction. La deuxième,  $Y$ , est un vecteur de même taille mais qui a été créé par une distribution gaussienne. De plus, ces deux vecteurs ont été normalisés selon les consignes de l'énoncé.

On obtient ainsi les histogrammes suivants :



On remarque que l'histogramme  $X$  présente distinguement 2 bosses, alors que l'histogramme  $Y$  une seule. Ainsi, on peut visualisé qu'on a deux clusters pour le vecteur  $X$ , et un seul pour le vecteur  $Y$ . On s'attend donc à retrouver des différences dans leurs attributs statistiques, et plus particulièrement dans leurs moments.


A l'aide des formules données dans l'énoncé du travail, on obtient le graphe suivant pour les approximations des fonctions génératrices de moments. On remarque ainsi une symétrie axiale en zéro pour les données gaussiennes, tout comme son histogramme. Alors que pour les données de la photo de la jonction on remarque une légère asymétrie axiale en 0, qui peut s'expliquer par le fait que l'histogramme n'est pas symétrique en zéro avec un cluster plus grand sur la partie droite.



Moments de X: [ 1. 0. 4.97 -4.62 45.06 -86.28 542.92]

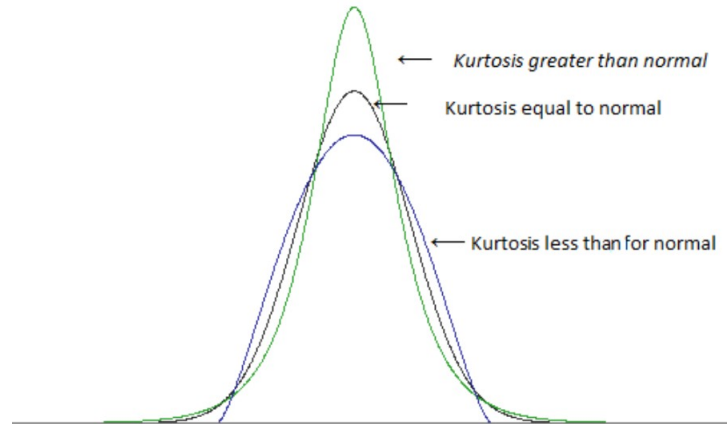
Moments de Y: [ 1. 0. 0.71 -0. 1.52 0. 5.41]

Le premier moment est l'espérance, et le second est la variance, on ne va pas approfondir ces deux sujets ici car ils ont déjà été abordés dans les précédents tps. Le troisième moment nommé skewness, mesure l'asymétrie de la distribution.

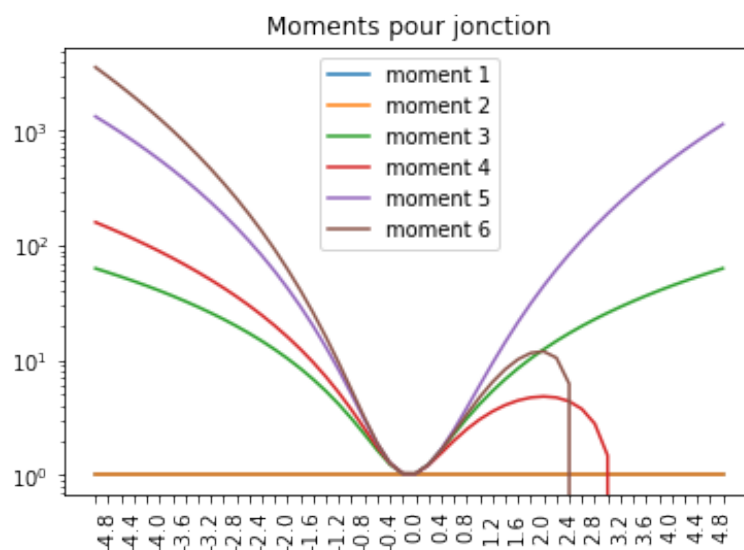



Etant donnée que nos deux valeurs sont positives, on est donc dans le premier cas de l'image ci-dessus. Mais on voit bien que le vecteur X a une asymétrie plus forte, alors que le vecteur Y est plus proche de 0.

Le 4<sup>ème</sup> moment, appelé kurtosis ou coefficient d'applatissage, il mesure la répartition des masses de probabilité autour de leur centre. Ainsi, il nous donne une idée à propos de comment est la fat tails de la distribution, c'est à dire à quelle fréquence des valeurs apparaissent très éloignées de nos données (événements très peu probables). Ainsi, on voit que avec les données gaussiennes des données "extrêmes" peuvent toujours avoir lieu, tandis que c'est moins le cas avec le vecteur X. De plus, pour X, vu que la valeur est négative, ceci implique une queue plus fine et un haut de courbe plus plat, ou des déviations plus grandes de l'espérance.



Pour le 5<sup>ème</sup> moment, on peut le visualiser comme une représentation du skewness de la queue. Pour les deux derniers moments je n'ai pas trouvé plus d'informations mais je suppose que le 6<sup>ème</sup> moment est lié au 4<sup>ème</sup> moment car il a un comportement semblable, alors que le 7<sup>ème</sup> moment doit être lié au 5<sup>ème</sup> car il a aussi un comportement semble, c'est à dire en terme statistique que ces données semblent corrélées.





On sait que la fonction caractéristique d'une variable aléatoire définit complètement sa distribution probabiliste. Si une variable aléatoire admet une pdf, alors la fonction caractéristique est la transformée de Fourier de la pdf.

On sait aussi qu'il suffit des deux premiers moments pour une variable aléatoire suivant une distribution gaussienne pour obtenir sa pdf. Mais, pour une variable aléatoire quelconque, il faudrait une infinité de moments pour obtenir sa pdf respective.

Ainsi, on obtient un résultat qui semble symétrique pour la fonction génératrice des moments du vecteur  $Y$ , tandis qu'on obtient un résultat nettement asymétrique pour le vecteur  $X$ . Ces résultats sont la conséquence de tout ce dont nous avons parlé dans le troisième exercice, et est un bon résumé de ce dernier.